

# 스마트폰 센서 기반 인간 활동 딥러닝 모델을 이용한 인식

S.Robini 씨, J.Fenila Naomi 씨

초록: 중요한 의도는 인간의 활동을 예상하여 인간 생명의 혐오감을 보장하는 모델을 생성하는 것입니다. 활동 인식(HAR)은 스마트폰을 사용하여 사람의 활력을 모니터링하는 것입니다. 스마트폰은 더 광범위한 방식으로 사용되고 있으며 스마트 모바일의 센서를 사용하여 인간의 환경 변화를 식별하는 방법 중 하나가 되었습니다. 스마트폰은 나침반 센서, 자이로스코프, GPS 센서 및 가속도계와 같은 센서를 감지하도록 장착되어 있습니다. 이 장치는 개인의 상태를 검사하는 것으로 사용되었습니다.

인간 활동 인식(HAR) 프레임워크는 센서에서 원시 데이터를 수집하고 다양한 딥러닝 접근 방식을 사용하여 인간의 움직임을 관찰합니다. 감지된 데이터를 사용하여 그럴듯한 높은 정확도로 인간의 동작을 식별하기 위한 딥러닝 모델이 제안됩니다. UCI 데이터 세트 저장소의 HAR 데이터 세트가 활용됩니다. 프레임워크의 성능은 원시 데이터만을 사용하여 장단기 메모리를 갖춘 합성곱 신경망(ConvLSTM)과 장단기 메모리를 갖춘 순환 신경망(RNNLSTM)을 사용하여 분석됩니다.

모델의 행위는 정확성과 효율성 측면에서 분석됩니다. 설계된 활동 인식 모델은 인간의 행동을 모니터링하여 모든 질병을 예측하기 위해 의료 분야에서 조차될 수 있습니다.

색인 용어: ConvLSTM, 딥러닝, 인간 활동 인식, RNNLSTM.

## I. 서론

스마트폰은 사용자에게 일상 활동에서 지능적인 지원을 제공하는 첨단 기술과 소통하기 위한 일상 생활에서 가장 유용한 도구가 되었습니다. 컴퓨팅 능력과 상호 연결성을 갖춘 휴대용 작업 프레임워크, 외부 도구와 애플리케이션을 실행하기 위한 애플리케이션 프로그래밍 인터페이스(API), 모바일 폰은 카메라, GPS, 웹 브라우저 등과 같은 하이라이트를 가지고 있으며 가속도계, 자이로스코프 및 자력계와 같은 이식된 센서[13]를 통해 클라이언트의 특정 영역, 움직임 및 상황을 고려하여 애플리케이션을 개선했을 수 있습니다. 수만 있는 스마트폰 애플리케이션을 개발하려면 가젯 클라이언트의 상황 인식 및 상황적 주의를 활용하는 것이 필수적입니다. 활동 인식은 이러한 장치들을 위한 그러한 플랫폼 중 하나로, 암묵적 센서로 처리할 수 있으며 비즈니스, 의료와 같은 다양한 분야에서 사용되고 있습니다.

서비스, 보안, 운송 등. 다양한 종류의 센서에는 움직임을 식별할 수 있는 웨어러블 센서와 정보 통신 채널을 활용하여 한 기기에서 다른 기기로 정보를 교환할 수 있는 Bluetooth 센서가 포함되어 있습니다. [2][22]. 이러한 휴대용 센서를 사용하면 피사체를 지속적으로 인식하는 데 도움이 되므로 감지 및 기록이 가능해집니다. 선호하는 환경에서 모니터링하는 동안 활동을 보 관할 수도 있습니다. [5].

인간 이동 인식은 의료, 스마트 환경 및 국가 안보에 다양한 응용 분야가 있는 중요하면서 도 어려운 시험 분야입니다. [9][23]

PC 버전 기반 전략은 일반적으로 인간의 움직임 모니터링에 활용되었습니다[17]. 점점 더 능숙해지는 방법론은 클라이언트의 신체에 착용한 관성 추정 장치 센서[3][10]에서 정보를 처리하거나 클라이언트의 모바일 폰에서 작동하여 움직임을 추적하는 것입니다. 전화에 내장된 단속 3축 가속도계에서 수집한 정보를 활용하여 실제 세계 조건에서 다양한 활동을 인식하는 데 적합한 모델이 구축되었습니다[12][11]. 속도와 변위를 평가할 수 있는 x, y 및 z 축을 따라 가속도 게이지를 반환하는 3축 가속도계입니다.

활동 인식은 개인이 자신과 주변 환경에 대한 고정된 인식을 바탕으로 수행한 움직임을 인식하는 데 관심이 있습니다. 인식은 관성 센서에서 복구된 데이터를 활용하여 인스턴스로 실행될 수 있습니다. 일부 스마트 기기에서 센서는 기본값을 사용하여 삽입되며 제한된 리소스가 있는 하드웨어에 대한 관성 프레임 마커를 처리하여 서기, 누워 있기, 걷기, 앉기, 위층으로 스크롤하기, 아래층으로 스크롤하기와 같은 일련의 신체 활동을 분류합니다.

스마트 기기에서 접근 가능한 제한된 메모리를 고려한 통제한 훈련 현실을 가진 분류기의 전반적인 실행. 훈련 기록을 축적하고 범주 단계에 직접 활용되는 경향이 있어 클라이언트의 가중치가 감소합니다. 논문은 다음과 같이 구성됩니다. 섹션 II는 관련 작업을 설명하고 섹션 III는 인간 활동 인식(HAR) 시스템에서 스마트폰에 사용되는 센서를 설명합니다. 섹션 IV는 제안된 기술을 설명하고 섹션 V는 실험 결과를 설명하고 마지막으로 섹션 VI는 결론을 설명합니다.

## II. 관련 작업

Min et al [14]은 가속도 센서 데이터만을 사용하는 모델과 가속도 센서 데이터 외에 위치 정보를 사용하는 모델 두 가지를 설계했습니다.

2019년 5월 30일에 수정된 원고가 접수되었습니다.

\* 통신 저자

Ms.S.Robini\*, 컴퓨터 과학 및 공학과,  
인도, 타밀나두 주, श्री 크리슈나 공학 및 기술 대학.

Ms.J.Fenila Naomi, 컴퓨터 과학 및 공학과, Sri Krishna College of Engineering and Technology, TamilNadu, India

© 저자. Blue Eyes Intelligence Engineering and Sciences Publication(BEIESP)에서 출판. 이것은 오픈 액세스입니다. CC-BY-NC-ND 라이선스에 따른 기사 <http://creativecommons.org/licenses/by-nc-nd/4.0/>

## 딥러닝 모델을 이용한 스마트폰 센서 기반 인간 활동 인식

특징 추출 전에 가속도 센서 데이터는 시간 세그먼트로 나뉘는데, 이를 시간적 분할이라고 합니다. 데이터 스트리밍을 처리하기 위해 슬라이딩 윈도우 기법을 사용합니다. 시간 윈도우의 구성 요소 벡터는 분류기에 기여하는 것으로 활용됩니다.

지역 데이터를 활용하면 점점 더 명확하고 세부화된 지역 기반 분류기를 연결할 수 있습니다.

위치 정보는 프레임워크에서 수집되지 않으며 다양한 종류의 활동에서 파생됩니다. 인공 신경망(ANN) 분류기에서 Xavier와 ReLU는 일반적으로 머신 러닝 분야에서 학습 시간을 줄이는데 사용됩니다. 학습률은 0.01로 설정되고 Adam 간소화 에이전트는 빠르게 훌륭한 결과를 달성하는 것으로 알려져 있기 때문에 활용됩니다. 마지막으로 위치 정보가 있는 모델은 95%의 정확도를 보이고 위치 정보가 없는 모델은 90%의 정확도를 보입니다.

Qingzhong et al [18]은 두 단계로 활동 인식을 위한 방법을 제안합니다. 1단계에서 가속도계는 모바일 폰의 동작과 경로를 인식하는 정제되지 않은 센서 데이터를 제공하며, 이는 자이로스코프가 사람이 감지하기에는 큰 회전 운동을 감지한다는 것을 나타냅니다. 2단계에서 감지된 데이터에 대한 특징 추출 방법이 수행됩니다. 머신 러닝 모델은 동작 인식을 위해 작동했으며, 그 시점에서 합성곱 신경망에 의존하는 심층 학습 모델이 작동했습니다. 결과는 일관성을 나타내는 것으로 입증되었으며, 다중 클래스 데이터 세트로 수집된 정보를 활용하면 활동 인식의 범위를 확장할 수 있을 것으로 예상됩니다.

실험 결과는 LibSVM이 모든 배열에서 FLD보다 정밀도 면에서 더 나은 성능을 보인다는 것을 보여줍니다. 결과에서 가속도계 센서(A-센서) 판독이 G-센서 판독(자이로스코프 센서)에 비해 더 많은 기여를 하지만 A와 심층 학습 계산을 모두 활용함으로써 탐지 정확도를 높일 수 있다는 추론이 가능합니다.

Erhan et al [4]은 의사결정 트리, 지원 벡터 머신, K-최근접 이웃(KNN) 및 부스팅, 배깅, 스태킹과 같은 앙상블 분류 방법과 같은 여러 가지 지도 학습 알고리즘을 제안합니다. 분류를 위해 정확도가 53.1%인 이진 의사결정 트리가 사용됩니다. 분기 한계를 100으로 늘리면 정확도가 94.4%로 증가합니다.

지원 벡터 머신은 초차원 평면을 사용하여 99.4%의 정확도를 제공합니다. K-NN은 k 값이 3으로 설정된 경우 97.1%의 향상된 효율성을 제공합니다. 앙상블 분류기에는 부스팅 기술이 다른 형태를 갖는 다양한 접근 방식이 있습니다. AdaBoost는 잘못 계산된 확률을 사용하고 97.4%의 정확도로 분류합니다. 다른 방법은 98.1%의 효율성으로 민감한 학습 알고리즘에서 의도 결과를 얻는 데 사용되는 배경입니다. 세 번째 방법은 30개의 스택 분류기를 적용하고 98.6%의 정확도를 예측하는 스태킹입니다.

Akram et al [1]은 사람의 다양한 활동을 분석하여 특징 선택을 기반으로 분류 모델을 구축합니다. Weka 툴킷에서 다층 퍼셉트론, 랜덤 포레스트, LMT, SVM, Simple Logistic 및 LogitBoost를 개별 및 결합 분류기로 비교한 다음 K-폴드 교차 검증을 사용하여 검증했습니다. 인식은 손에 든 모바일로 분석됩니다.

그리고 주머니 위치. SVM이 손에서 더 나은 정밀도를 제공하고 랜덤 포레스트가 가장 높은 정확도를 지시하기 때문에 효율성이 높아집니다. 휴대전화 손 위치, 다층 퍼셉트론, 로짓 부스트 및 SVM 분류기의 융합은 91.15%의 정확도를 제공하지만 주머니 위치, 다층 퍼셉트론, 랜덤 포레스트 및 심플

정확도 90.34%의 로지스틱. 단일 3축 가속도계를 사용하여 일상 활동에서 91.15%의 정확한 인식을 얻었습니다.

### III. 스마트폰의 센서

스마트 가젯은 움직임(가속도계, 중력 센서, 스피너), 방향(자기계) 및 독특한 생태적 조건(마커, 광도계, 온도계)을 측정하는 센서와 함께 작동했습니다. 기어 기반 센서는 PDA와 통합된 물리적 부품이며, 특정 공통 매개변수를 명시적으로 평가하여 정제되지 않은 데이터를 수집합니다. 프로그래밍 기반 센서는 장비 기반 센서를 가장하는 방식임에도 불구하고 물리적 장치가 아닙니다. 이러한 센서는 높은 정확도로 정보를 제공하는 데 적합하며 3차원 장치 개발을 스크린 할 것으로 예상되는 경우 중요합니다.

안드로이드 센서 프레임워크는 다양한 종류의 센서를 얻을 수 있도록 하고, 센서 구조는 표준 3-센서 포인트 배열을 사용하여 데이터를 표현합니다. 장치가 기본 소개에 보관되면 X-허브는 바닥과 수평이 되어 오른쪽을 표시하고, Y 센서는 수직이며 위를 향하고, Z 턴은 화면 표면의 외부를 표시합니다. 이 구조에서 화면 뒤의 오케스트레이션은 음의 Z 값을 갖습니다. 그림 1은 인간 활동 인식(HAR)을 위해 스마트폰에서 사용할 수 있는 센서를 나타냅니다.

#### A. 가속도계

가속도계는 스마트폰과 예리한 옷장에 필수적인 장비 중 하나입니다. 필수적인 한계는 데이터에 대한 스마트 가젯의 방향 변화를 식별하고 클라이언트의 연구 가장자리에 맞게 소개를 조정하는 것입니다. 예를 들어, 확장된 너비의 사이트 페이지를 스캔할 때 전화기의 방향을 레벨로 변경하여 이 장면을 볼 수 있습니다. 독특한 방식 카메라 모드는 가젯/카메라의 방향이 변경될 때 장면을 표현으로 또는 사진을 장면으로 변경합니다. 장기적으로 이 센서는 자유 낙하와 관련된 장치의 증가 속도의 3D(X, Y 및 Z 회전) [21] 추정에 의한 변화를 감지합니다.

#### 나. 자이로스코프

자이로스코프의 활용은 정확한 에너지의 표준에 따라 위치, 레벨 또는 방향을 유지하고 제어하는 것입니다. 어떤 시점에서든 근처 가속도계가 사용된 '자이로스'는 오른쪽, 왼쪽, 위, 아래, 앞, 역과 같은 6축에서 개발을 식별합니다. 그것은 움직임, 피치, 요 개발을 구별합니다. 요, 롤, 피치는 3축에서 보이는 정확한 분입니다.

MEMS(Micro Electrical and Mechanical System) 혁신을 사용하여 자이로스코프 센서는 경로 추론과 예리한 모바일과 태블릿에 사용되는 동작 구조를 인식하는 데 도움이 됩니다. 그림 1은 스마트폰의 센서를 나타냅니다.

#### C. 나침반 센서

스마트 나침반은 매력적인 필드의 남북 샤프트에 대한 방향을 인식하는 표준 가젯입니다. 모바일 폰의 나침반 유용성은 자력계라고 하는 점점 더 예측할 수 없는 센서입니다. 그것은 매력적인 필드의 품질과 과정을 평가하는 데 사용됩니다. 센서는 지구 자기장을 분해함으로써 가젯이 높은 정확도로 방향을 선택할 수 있도록 합니다[8]. 나침반 센서는 0o와 360o 범위 어딘가에 있는 부표 번호입니다.

여 북쪽은 현재 휴대전화 경로와 시계 방향으로 북쪽 사이의 지점을 보여줍니다. 속도계와 SMS 또는 이메일 방법으로 GPS 마스터마인드를 보내는 선택. 나침반 센서에서 돌아온 정보 스트림은 거룩한 메신저인 명칭함을 보여주는 많은 표류 숫자입니다( $i=D 1, 2, 3, \dots 0o \leq \text{컴파} \leq 360o$ ). 나침반 탐색은 클라이언트의 움직임에서 범위 변화를 구별하는 데 사용할 수 있습니다.

그림 1 스마트폰의 센서

#### D. GPS[Global Positioning Sensor] 시스템

글로벌 포지셔닝 시스템(GPS)은 처음에는 군사적 임무를 위해 만들어지고 설정되었으며 1980년대에 정부에서 모든 사람이 사용할 수 있게 되었습니다. GPS는 GPS 위성의 도움으로 그림이나 가이드로 목표를 추적하거나 사물을 '탐색'하는 시스템입니다. 여러 휴대전화가 탐색 하이라이트를 위한 GLONASS(Globalnaya Navigatsionnaya Sputnikovaya Sistema) GPS 구조를 지원합니다.

#### E. 가압계

무게 센서, 즉 측정 지표라고도 함 변화하는 공기 무게를 검사하여 상대적이고 직접적인 높이. 무게 센서는 높이에 대한 데이터가 중요할 수 있는 게임 및 웰빙 또는 지역 조립 애플리케이션을 위한 고객 가젯에서 활용될 수 있습니다. 공압 능력은 다양한 높이에 따라 변동하며 게이지는 일부 추진식 PDA에 준비된 최신 센서 중 하나입니다. 센서가 설치된 조건에 공기 무게를 측정합니다. 공압력은 다양한 높이에 따라 변합니다. 구조물 내부에 비슷한 높이의 지점이 있는 경우에도 마찬가지입니다. 이런 방식으로 게이지 읽기는 제한 관련 움직임 인식에서 클라이언트의 위치 변화를 보여주는 데 활용될 수 있습니다.


### IV. 방법론

본 논문에서 사용한 머신 러닝과 딥 러닝 방법은 다음과 같습니다.

#### A. 데이터 수집

데이터 세트는 19~48세 사이의 30명의 자원봉사자의 활동을 모니터링하여 준비되었습니다. 여섯 가지 다른 종류의 활동을 수행하는 각 사람은 아래에 나열되어 있습니다.

- 걷기
- 위층으로 걷기
- 계단을 내려가다



- 앉아있기
- 서 있음
- 놓기

이 데이터는 Human Activity Recognition [HAR]의 UCI Machine learning store에서 수집되었습니다. 내장된 가속도계와 자이로스코프를 활용하여 50Hz의 일정한 속도로 3축 선형 가속도와 3허브 정밀 속도를 포착했습니다. 획득한 데이터 세트는 임의로 분할되었습니다.

자원봉사자의 70%는 정보 준비, 30%는 테스트 정보로 선택되어 두 세트로 나뉩니다.

소음

채널은 사전 처리된 센서 신호에 연결되고 그 후 2.56초와 반 커버(창당 128개 판독 값)의 고정 너비 슬라이딩 창에서 검사됩니다.

중력 및 신체 움직임 세그먼트가 있는 센서 가속 신호는 Butterworth 저역 통과 채널을 사용하여 신체 가속 및 중력으로 분리되었습니다. 중력 전력은 낮은 재발 세그먼트를 가질 것으로 예상되며 0.3Hz 컷오프 재발이 있는 채널이 활용되었습니다. 모든 창에서 시간 및 재발 영역에서 요소를 확인하여 하이라이트 벡터를 획득했습니다. 마지막 데이터 세트는 561개의 하이라이트가 있는 2947개의 레코드로 구성됩니다. 각 레코드에 대해 다음을 제공합니다.

처럼:

- 가속도계로부터 추정된 신체 가속도 및 3축 가속도
- 자이로스코프의 3축 각속도.
- 활동 라벨. 분석을 수행할 수 있는 주체의 식별자.

#### B. K-최근접 이웃

K-Nearest Neighbor는 패턴 인식을 위한 가장 주류 알고리즘 중 하나인 지도 학습 알고리즘입니다[20]. K-Nearest Neighbor 알고리즘은 예상 예측으로 이웃 특성을 활용합니다. 기존의 K-NN 콘텐츠 분류 알고리즘에는 세 가지 제약이 있습니다. (a) 모든 준비 테스트를 순서대로 사용하기 때문에 계산이 예측 불가능하고, (b) 실행은 준비 세트에만 적용되며, (c) 테스트 간에 가중치 구분이 없습니다. 노이즈나 부적절한 특징이 있는 경우 K-NN 알고리즘의 정확성이 떨어질 수 있습니다. 패턴 인식에서 K-NN은 요소에서 가장 가까운 학습 특징을 기반으로 객체를 배열하는 기술입니다.

공간.

## 딥러닝 모델을 이용한 스마트폰 센서 기반 인간 활동 인식

### C. 분류 및 회귀 트리

분류 및 회귀 트리 알고리즘은 비교 속성을 가진 다양한 예제를 모아서 샘플을 특성 화합니다. 동안

준비, 준비 정보는 지속적으로 더 작은 하위 집합으로 분리됩니다. 분할이 완료되는 시점에서 예제는 속성에 따라 그룹화됩니다[15]. 그런 다음 테스트 테스트는 모든 허브의 특정 조건에 대해 평가되고 트리 전체에 생성됩니다. 예제가 리프 허브에 도달하는 시점에서 해당 허브의 예제가 있는 클래스가 분배됩니다. 이 논문에서는 합법적인 조건이 있는 병렬 트리가 사용되었습니다. 트리는 여전히 광범위한 연구 중이며 독립적인 분류기 또는 더 큰 알고리즘 구조의 일부로 사용될 수 있습니다.

### D. 지원 벡터 머신

머신 러닝에서 지원 벡터 머신은 정보를 조사하고 그룹화하기 위한 학습 알고리즘과 관련된 모델입니다. SVM 알고리즘은 가이드를 하나 또는 다른 클래스 구분에 할당하는 모델을 만듭니다[20].

이 모델은 다른 클래스로 분리되는 선례를 매핑합니다. SVM도 마찬가지로 비직접적인 순서를 수행할 수 있습니다. SVM의 활동은 초평면에 따라 달라집니다. SVM의 작업은 준비 모델에 가장 큰 최소 분리를 제공하는 초평면에 따라 달라집니다. 속성은 차원 감소를 구현한 후에 취해집니다.

기술.

### E. 랜덤 포레스트

랜덤 포레스트는 가지치기되지 않은 수요의 복잡하거나 다양한 의사결정 트리를 가진 부트스트래핑 알고리즘처럼 내려갑니다. 각 트리는 예측 불가능하고 독립적으로 선택된 벡터의 추정에 따라 달라집니다. .랜덤 포레스트

단일 트리 분류기[21]보다 훨씬 더 뛰어난 개선 효과를 제공합니다. 각 트리는 알고리즘을 사용하여 제작됩니다.

계획 사례의 양을  $N$ 이라 하고, 분류기의 구성 요소 수를  $M$ 이라 하자. • 트리의 허브에서 선택을 하는 데 사용할 입력 구성 요소의 수  $m$ .

$m$ 은 정확히  $M$ 이 아니라 상당히 커야 한다.

- 모든  $N$ 개의 사용 가능한 준비 케이스에서 대체를 통해  $n$ 번을 선택하여 트리에 대한 준비 세트를 선택합니다. 케이스의 나머지 부분을 사용하여 클래스를 구성하여 오류를 평가합니다. • 트리의 각 허브에 대해 해당 허브에서 결정을 내릴  $m$ 개의 요소를 무심코 선택합니다.

- 이러한  $m$ 에 따라 최상의 분할을 계산합니다.

준비 세트의 요소

- 각 나무는 완전히 생성되었으며 (일반적인 나무 분류기의 구조에서 수행될 수 있는 것처럼) 가지치기가 수행되지 않았습니다.

### F. 추가 트리

Extra-Trees 알고리즘은 확립된 상향식 방법론에서 표시된 대로 가지치기되지 않은 선택 또는 재발 트리의 앙상블을 구성합니다. 다른 트리 기반 그룹 기술과의 두 가지 주요 대조점은 완전히 목적 없이 절단 초점을 선택하여 허브를 분할하고 전체 학습 테스트(부트스트래핑 재샘플과 대조적으로)를 사용하여 트리를 개발한다는 것입니다. 수학적 특성에 대한 Extra-Trees 부분 방법론에는 두 가지 매개변수가 있습니다.  $K$ , 임의의 특성의 양

모든 허브와  $nmin$ 에서 선택했습니다. 고유한 학습 테스트와 함께 몇 번 사용하여 그룹 모델을 만듭니다. 매개변수  $K$ ,  $nmin$  및  $M$ 은 다양한 영향을 미칩니다.  $K$ 는 특정 결정 프로세스의 품질을 결정하고  $nmin$ 은 수확량 노이즈 평균화의 품질을 결정하며  $M$ 은 변동의 품질로 전체 앙상블 모델을 줄입니다. 이러한

매개변수는 수동 또는 프로그래밍 방식으로 관심 있는 문제 지점에 맞게 조정될 수 있습니다.

### G. 그래디언트 부스팅

그래디언트 부스팅은 재발 및 주문 문제에 대한 AI 방법으로, 일반적으로 선택 트리인 무력한 예측 모델 그룹으로 기대 모델을 생성합니다. 모든 지향 학습 알고리즘의 목표는 불행한 작업을 특성화하고 제한하는 것입니다[20]. 그래디언트 부스팅 머신은 다수의 약한 학습자 트리가 단일 트리보다 선호하는 예측을 제공하기 위해 그룹으로 혼합되어 사용되는 선택 트리 앙상블에 기반합니다. 부스트는 타의 추종을 불허하는 정규화와 누락된 품질에 대한 더 나은 처리, 그리고 크게 향상된 효율성을 제공합니다.

### H. LSTM을 사용한 합성 신경망

CNN Long Short-Term Memory Network 설계에는 LSTM과 결합된 입력 정보에 대한 기능 추출을 위해 합성곱 신경망(CNN) 계층을 활용하여 배열 예측을 돕습니다. CNN LSTM은 시각적 시간 배열 예측 문제와 연속된 이미지에서 문학적 묘사를 생성하는 데 활용하기 위해 만들어졌습니다. 하이라이트 추출을 위한 CNN 모델과 시간 단계에 따라 하이라이트를 가로질러 해독하기 위한 LSTM 모델의 두 가지 하위 모델을 특징으로 합니다. Conv2D 및 Max Pooling 2D 계층이 포함된 2D 합성곱 시스템을 입니다. 각 정보 그림에 CNN 모델을 적용하고 각 정보 그림의 수열을 LSTM에 단독 시간 단계로 전달합니다.

CNN 입력 모델 전체(한 개 이상의 레이어)를 시간 분산 레이어로 래핑합니다. 이 레이어는 서로 다른 경우에 유사한 레이어나 레이어를 적용하는 이상적인 결과를 달성합니다. 이들은 콘텐츠를 인식하고 자동으로 표현하는 데 매우 강력함을 보여주었습니다.

### I. LSTM을 이용한 순환 신경망

순환 신경망(RNN)은 놀랍고 강력한 신경 시스템이며 내부 메모리를 가진 주요 시스템이므로 가장 고무적인 알고리즘과 함께 자리를 잡았습니다. RNN에서 데이터는 원을 통과합니다. 선택을 할 때 현재 기능과 이전 소스에서 얻은 내용을 고려합니다. 순환 신경망은 빠른 과거를 현재에 추가합니다. RNN은 다수, 다수 대 다수(해석) 및 다수 대 1을 구분할 수 있습니다. RNN이 관리해야 하는 두 가지 주목할 만한 장애물이 있습니다.

- 기울기는 입력에 대한 분수 종속 변수입니다. 기울기는 정보 소스를 약간 변경했을 때 용량의 수열이 얼마나 변하는지 추정합니다. • 각도가 높을수록 기울기가 더 심해지고 모델이 더 빨리 학습할 수 있습니다. 기울기가 0이면 모델은 학습을 멈춥니다.



경사는 오차의 조정과 관련된 모든 하중의 조정만을 추정합니다.

그들의 데이터는 메모리에 저장됩니다.

장기 단기 메모리(LSTM) 시스템은 근본적으로 메모리를 확장합니다. LSTM의 단위는 RNN 계층의 구조 단위로 활용되며, 이를 일반적으로 LSTM이라고 하며, 이를 통해 RNN이 장기 입력을 가질 수 있습니다. LSTM은 RNN이 다음을 회상할 수 있도록 합니다.




그림 2 스마트폰으로부터 데이터를 수집하고 저장하는 과정

## V. 시스템 구조

### A. 인간 활동 인식[HAR]

인간 활동 인식은 걷기, 위층 걷기, 아래층 걷기, 앉기, 서기, 누워 있기 등의 활동을 포함하여 사람들이 수행하는 활동을 모니터링하는 것입니다. 흐름은 스마트폰에서 데이터를 수집하고 저장하는 과정을 보여주는 그림 2와 같이 작동합니다.

- 개인은 스마트폰을 휴대하고 있으며 수집된 데이터는 스마트폰의 메모리에 저장됩니다. • 수집된 정보는 서버에 전달되고

저장됨.

- 각 활동에는 사전 정의된 훈련 세트가 있으며 분류 프로세스를 통해 템플릿과 비교됩니다.

HAR 모델의 정확도는 배치된 분류기에 따라 달라집니다.

### B. 제안된 시스템


제안된 HAR은 두 가지 모델로 설계되었습니다. 한 모델은 LSTM이 있는 CNN을 사용하고 다른 모델은 LSTM이 있는 RNN으로 배포됩니다. 처음에는 Human Activity Recognition [HAR]이라는 데이터 세트가 UCI 머신 러닝 저장소에서 수집되었습니다. 데이터 세트는 노이즈 필터를 사용하여 전처리됩니다.

전처리 후 데이터는 고정된 창으로 분할됩니다.

특징 엔지니어링 기술이 윈도우 데이터에 적용됩니다.

윈도우 데이터는 70%의 훈련 세트와 30%의 테스트 세트로 분할됩니다. Feature Engineering에는 다음 섹션이 있습니다.


주로, 총 가속도, 신체 가속도, 자이로스코프와 같은 세 가지 주요 신호 유형을 가진 데이터 세트가 로드됩니다. 그런 다음 LSTM 네트워크 모델을 개발합니다. LSTM은 긴 데이터 시퀀스를 통해 학습하고 기억할 수 있습니다. 이 모델은 여러 활동 시퀀스를 지원할 수 있습니다. 모델링 후 LSTM을 정의, 적합 및 평가해야 합니다. 그런 다음,



CNN(Convolution Neural Network)과 RNN(Recurrent Neural Network)이 LSTM 모델과 함께 적용되어 예측을 수행합니다. 제안된 시스템 작업 흐름은 그림 3에 나와 있습니다.

# 딥러닝 모델을 이용한 스마트폰 센서 기반 인간 활동 인식

그림 3 설계된 모델의 작업 흐름



무화과.

각 활동에 대한 4개의 가속도계 신호

분류자	정확성 (%)	평균 순수한 오류 [MAE]	평균 제공근 제공 오류 [RMSE]	절대 평균 백분율 오류 [MAPE] (%)
K- 최근접 이웃 [K-NN]	61.893	4.87	5.33	58
분류 및 회귀 나무 [장바구니]	72.14	2.987	3.08	49.4
지원 벡터 머신 [SVM]	76.96	2.68	2.96	46.7
랜덤 포레스트	84.66	0.4	1.245	15.8
여분의 나무	86.90	0.02	0.0554	6.90
그래디언트 부스팅	87.61	0.0128	0.0336	6.78
합성 신경망 통찰을 이용한 네트워크 용어 기억 [ConvLSTM]	92.24	0.0007	0.0044	5.91
장기 단기 순환 신경망 메모리 [RNNLSTM]	93.89	0.0004	0.0024	4.78

표 1 분류기의 성능 측정 항목

## VI. 실험 결과

이 실험에서 인간의 활동은 전처리로 시작된 움직임을 기반으로 인식됩니다. ConvLSTM과 RNNLSTM이 분류기로 사용됩니다. 여섯 가지 활동 모두에 대한 가속도계 데이터는 그림 4에 표시됩니다. 모델의 성능은 정확도, 평균 절대 오차[MAE], 평균 제공근 오차[RMSE] 및 평균 절대 백분율 오차[MAPE]를 기반으로 검증됩니다.

이러한 품질이 작을수록 기대치가 더 좋습니다. 표 1은 설계된 모델의 성능을 보여줍니다.

## 나. 결과

실험은 Python 3.x 버전에서 수행되었습니다.

제안된 모델에 대한 결과는 표 1, 그림 5 및 6에 나와 있습니다. 결과에 따르면 장단기 메모리를 갖춘 순환 신경망[RNNLSTM]이 더 낮은 평균 절대 백분율 오차[MAPE]로 더 나은 정확도를 제공합니다. RNNLSTM은 93.89%의 더 균형 잡힌 정확도, 0.0004의 평균 절대 오차[MAE], 0.0024의 평균 제공근 오차[RMSE] 및 4.78%의 평균 절대 백분율 오차[MAPE]를 갖습니다. 이로 인해 RNNLSTM은 인명 손실을 줄이기 위해 실제 응용 프로그램에서 인간 활동을 인식하는 데 사용될 수 있습니다. 그림 5는 다양한 분류기의 정확도를 비교한 것이고 그림 6은 MAE, RMSE 및 MAPE를 비교한 것입니다.




그림 5. 다양한 모델의 정확도 비교

## A. 성과 지표

MAE는 측정된 데이터 세트에 대한 일반적인 테스트입니다.

예측과 실제 인식 사이에 엄청난 차이가 있습니다.

제공 평균 오차(RMSE)는 오류의 정상적인 크기를 추정하는 이차 검도 규칙입니다. 예측과 실제 인식 사이의 제공된 다양성의 정상적인 제공 밀입니다. MAE 평가는 다음과 같아야 합니다.

RMSE와 정확히 같지 않거나 동일하지 않습니다. MAPE는 기계 기술의 정확성을 정량화하는 데 사용됩니다. 정기적으로,

## VII. 결론

스마트폰은 널리 보급되어 점점 더 현대화되고 있습니다. 이는 개인의 일상 생활의 장면을 바꾸어 왔고 매혹적인 정보 마이닝 애플리케이션의 입구를 열었습니다. 인간 행동 인식은 이러한 애플리케이션 뒤에 있는 중심 구조입니다. 원시 센서의 읽기를 정보의 원천으로 삼고 클라이언트의 움직임 행동을 예측합니다. 이 논문은 PDA 센서를 사용한 다양한 움직임 인식의 최대 93.89%까지의 진행 중인 발전에 대한 광범위한 개요를 보여줍니다. 다양한 분류기의 정보는 인식 실행을 평가하는 데 사용되었습니다.

여러 분류기를 통합하여 확률 전략의 정상을 활용하는 최상의 분류기가 움직임 인식에 가장 적합한 분류기로 판명되어 다른 모든 분류기보다 성능이 우수했습니다.

## 딥러닝 모델을 이용한 스마트폰 센서 기반 인간 활동 인식




그림 6. 다양한 모델에 대한 MAE, RMSE 및 MAPE 비교

인지 전략은 휴대전화 위치와 무관한 운동을 식별할 수 있음을 보여주었습니다. 향후 작업을 위해 몇 가지 다른 방식으로 움직임 인지 작업을 수행합니다. 우선 추가 운동을 인식할 계획을 세웁니다. 둘째, 다양한 연령대의 더 많은 고객으로부터 정보를 수집하고자 합니다. 셋째, 다양한 운동을 더 잘 구분할 수 있는 하이라이트를 더 많이 제거하려고 합니다.

## 참고문헌

1. Akram Bayat, Marc Pomplun, Duc A. Tran, "인간에 관한 연구" 스마트폰의 가속도계 데이터를 활용한 활동 인식", 매사추세츠 대학교 컴퓨터 과학부, 보스턴, 100 Morrissey Blvd Boston, MA 02125, 미국, Elsevier Procedia Computer Science, 제 34권, 450-457호, 2014년.
2. T. Brezmes, JL Gorricho 및 J. Cotrina, "모바일 폰의 가속도계 데이터에서 활동 인식", IWANN '09: Proc. the 10th 인공지능국 국제작업회의, 796-799, 2009.
3. Casale Pierluigi, Pujol Oriol 및 RadevaPetia, "웨어러블 장치를 사용한 가속도계 데이터에서 인간 활동 인식", 패턴 인식 및 이미지 분석, Springer, 289-296, 2011.
4. Erhan BÜLBÜL, Aydin Çetin 및 Ibrahim Alper DOĞRU, "스마트폰을 사용한 인간 활동 인식", IEEE, 978-1-5386-4184-2, 2018.
5. J. Goldman et al, "참여형 감지: 우리 세계를 형성하는 패턴을 밝히기 위한 시민 주도적 접근 방식", 2009.
6. N. Gyorbiro, A. Fabian 및 G. Homanyi, "휴대전화용 활동 인식 시스템", Mobile Networks and Applications [MONET], 제14권, 1호, 82-91쪽, 2009년 2월.
7. Jian\_Sun, Yongling\_Fu, Shengguang\_Li, Jie\_He, Cheng\_Xu 및 LinTan, "웨어러블 센서를 사용한 딥 컨볼루션 네트워크 및 엑스트림 러닝 마신 기반 순차적 인간 활동 인식" 연구 기사, Journal of sensor, 2018.
8. Jubil T Sunny Sonia Mary George와 Jubilant J Kizhakkethottam, "스마트 환경에서 센서를 사용한 인간 활동 인식의 응용 및 과제", 컴퓨터 과학 및 공학, St. Joseph's College of Engineering and Technology, Palai, Kerala, International Journal for Innovative Research in Science & Technology | Volume 2 | Issue 04 | September 2015.
9. Khan, Adil Mehmood, Lee, Young-Koo Lee, Sungyoung Y 및 Kim, Tae-Seong, 중강 신호 특징 및 계층적 인식을 통한 3축 가속도계 기반 신체 활동 인식, 생물학 분야 정보 기술, IEEE Transactions, 2010.
10. Krishnan Narayanan C, Colby Dirk, Juillard Colin 및 Panchanathan Sethuraman, "3축 가속도계를 사용한 실시간 인간 활동 인식", 센서 신호 및 정보 처리 워크숍, 2008년
11. Kwapisz, Jennifer R Weiss, Gary M 및 Moore Samuel A, "휴대전화 기반 생체 인식 식별, 생체 인식: 이론 응용 및 시스템(BTAS)", 제4회 IEEE 국제 컨퍼런스, 2010년.
12. Kwapisz, Jennifer R Weiss, Gary M 및 Moore Samuel A, "휴대전화 가속도계를 사용한 활동 인식", ACM SigKDD Explorations Newsletter, 2011.
13. ND Lane, E. Miluzzo, H. Lu, D. Peebles, T. Choudhury 및 A. T. Campbell, "모바일폰 감지에 대한 조사", IEEE Commun. Mag, Vol. 48, PP.140-150, 2010년 9월.
14. 권민철, 최선웅, "인공신경망과 스마트워치를 활용한 일상적 인간 활동 인식" ,무선 통신 및 모바일 컴퓨팅, 2018.
15. 파벨 도날레, Petr Gajdo 및 Tomáš Peterek, "인간 활동 인식: 여러 데이터 세트에 대한 분류기 성능 평가", 진동공학 저널, 제16권, 3호, 2014년.
16. Pierre Geurts, Damien Ernst 및 LouisWehenkel, "매우 무작위화된 트리" 리서치 게이트, 2006년 4월.
17. Poppe Ronald, "바전 기반 인간 행동 인식에 대한 조사", 이미지 및 바전 컴퓨팅, Elsevier, 2010.
18. Qingzhong Liu, Zhaoxian Zhou, Sarbagya Ratna Shaky, Prathyusha Uduthalapally, Mengyu Qiao, Andrew H. Sung, "기계 학습 및 딥 러닝 알고리즘을 사용한 스마트폰 센서 기반 활동 인식" International Journal of Machine Learning and Computing, 제8권, 제2호, 2018년 4월
19. Sahak Kaghyan, Hakob Sarukhanyan, "3축 가속도계가 있는 스마트폰에서 K-최근접 이웃 알고리즘을 사용한 활동 인식", 국제 저널 "Information Models and Analyses" Vol.1 / 2012.
20. KP Sanal Kumar 및 R. Bhavani, "SVM, KNN 및 결합된 SVM KNN 분류기를 사용한 자기중심 비디오의 활동 인식", IOP 컨퍼런스 시리즈: 재료 과학 및 엔지니어링, 2017
21. Sandeep Kumar Polu, "기계 학습 알고리즘을 사용한 스마트폰에서의 인간 활동 인식", 아차리아 나가르주나 대학교 정보기술학과, 과학기술 혁신 연구를 위한 국제 저널, 제5권 6호, 2018년 11월.
22. TS Saponas, J. Lester, JE Froehlich 외, "Iphone에서 Ilearn: 상용 모바일 폰에서 실시간 인간 활동 분류" CSE 기술 보고서, 2008년.
23. Westerterp, Klaas R, "신체 활동 평가: 비판적 평가, 유럽 응용 생리학 저널", 국립 생명공학 정보 센터, 2009.



## 작가 프로필



S. 루비니 씨는 1994년 인도 타밀나두 주 코임바토르에서 태어났습니다. 그녀는 2017년 코임바토르의 PSG 기술대학에서 기계공학 학위를 받았습니다.

그녀는 PG 과정에서 TANCET 장학금을 받았습니다. 그녀는 PG 과정에서 Best Project Award를 수상했습니다.

그녀는 SNS 기술대학에서 BE 학위를 받았습니다. 현재 그녀는 코임바토르의 Sri Krishna 공학 및 기술대학에서 조교수로 재직하고 있습니다. 그녀의 연구 분야는 클라우드 컴퓨팅, 데이터 마이닝 및 IoT입니다.

그녀는 국제 저널에 연구 논문을 발표했고, 국내 및 국제 컨퍼런스에서 5편 이상의 논문을 발표했습니다. 그녀는 인도 기술 교육 협회(ISTE)의 회원입니다.



J. Fenila Naomi 여사는 1993년 인도 타밀나두 주 코임바토르에서 태어났습니다. 그녀는 2018년 코임바토르의 PSG 기술대학에서 M.Tech 학위를 받았습니다. 그녀는 PG 과정에서 TANCET 장학금을 받았습니다. 그녀는 Hindusthan 공과대학에서 BE 학위를 받았습니다.

현재 그녀는 코임바토르의 Sri Krishna College of Engineering and Technology에서 조교수로 일하고 있습니다. 그녀의 연구 분야는 클라우드 컴퓨팅, 데이터 마이닝 및 IoT입니다. 그녀는 국제 및 국가 저널에 연구 논문을 발표했습니다.